

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ

Кафедра информационных систем управления

**ПРЕДОБРАБОТКА ИЗОБРАЖЕНИЙ ПРИ ПОМОЩИ
МАШИННОГО ОБУЧЕНИЯ И КЛАССИЧЕСКИХ МЕТОДОВ**

Курсовая работа

Яшенюк Алины Игоревны
обучающейся 3 курса специальности
«Прикладная информатика»

Научный руководитель:
кандидат технических наук,
доцент А.А. Воронов

Минск 2025

АННОТАЦИЯ

В курсовой работе рассмотрена проблема повышения качества изображений для задач компьютерного зрения в условиях наличия шумов, низкой контрастности и артефактов. На основе анализа современных методов обработки изображений выявлены преимущества и ограничения классических алгоритмов и нейросетевых подходов. Разработана гибридная система предобработки, объединяющая методы фильтрации, коррекции контраста и глубокое обучение. Система реализована в виде модульного программного обеспечения, поддерживающего стандарты данных и гибкую настройку этапов обработки. Тестирование подтвердило способность решения эффективно улучшать визуальное качество изображений и повышать точность их анализа.

АНАТАЦЫЯ

У курсавой працы разгледжана праблема павышэння якасці малюнкаў для задач камп'ютэрнага гледжання ва ўмовах наяўнасці шумоў, нізкай кантраснасці і артэфактаў. На аснове аналізу сучасных метадаў апрацоўкі малюнкаў выяўлены перавагі і абмежаванні класічных алгарытмаў і нейросетевых падыходаў. Распрацавана гібрыдная сістэма прадобработкі, якая аб'ядноўвае метады фільтрацыі, карэкцыі кантрасу і глыбокае навучанне. Сістэма рэалізавана ў выглядзе модульнага праграмнага забеспячэння, які падтрымлівае стандарты дадзеных і гнуткую наладу этапаў апрацоўкі. Тэставанне пацвердзіла здольнасць рашэння эфектыўна паляпшаць візуальнае якасць малюнкаў і павышаць дакладнасць іх аналізу.

ANNOTATION

The course work examines the problem of improving image quality for computer vision tasks in the presence of noise, low contrast and artifacts. Based on the analysis of modern image processing methods, the advantages and limitations of classical algorithms and neural network approaches have been identified. A hybrid preprocessing system has been developed that combines filtering, contrast correction, and deep learning methods. The system is implemented as modular software that supports data standards and flexible configuration of processing stages. Testing has confirmed the solution's ability to effectively improve the visual quality of images and improve the accuracy of their analysis.

РЕФЕРАТ

ПРЕДОБРАБОТКА ИЗОБРАЖЕНИЙ ПРИ ПОМОЩИ МАШИННОГО ОБУЧЕНИЯ И КЛАССИЧЕСКИХ МЕТОДОВ

Курсовой проект: 35 стр., 31 рис., 13 источников.

Объект исследования: методы и технологии предобработки изображений, объединяющие классические алгоритмы цифровой обработки сигналов и современные подходы машинного обучения.

Цель работы: разработка эффективной гибридной системы предобработки изображений для повышения качества визуальных данных, обеспечения точности их анализа и интеграции в прикладные задачи компьютерного зрения.

Методология проведения работы: системный анализ алгоритмов обработки изображений, инженерия гибридных решений, технологии разработки модульного ПО на Python, экспериментальная оценка на медицинских рентгенограммах.

Результаты работы: разработаны гибридные алгоритмы, сочетающие преимущества классических и машинных подходов, а также создано программное обеспечение для автоматизации процессов предобработки изображений.

Область применения результатов: медицинские информационные системы (обработка рентгеновских, КТ, МРТ-снимков), промышленный контроль качества, системы безопасности, спутниковый мониторинг.

При форматировании текста курсового проекта использовались стандарты ВАК АН РБ.

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	7
ГЛАВА 1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ПРЕДОБРАБОТКИ ИЗОБРАЖЕНИЙ.....	8
1.1 Обзор современных исследований	8
1.2 Классификация методов предобработки	9
1.3 Постановка исследовательской задачи.....	11
1.4 Выводы.....	11
ГЛАВА 2. МОДЕЛИ И АЛГОРИТМЫ ПРЕДОБРАБОТКИ.....	12
2.1 Классические алгоритмы.....	12
2.2 Методы машинного обучения.....	13
2.2.1 Архитектуры нейросетей для предобработки	13
2.2.2 Обучение и тонкая настройка моделей.....	14
2.3 Гибридные подходы в предобработке изображений	15
2.3.1 Принципы построения гибридных систем	15
2.3.2 Практические реализации гибридных подходов.....	15
2.3.3 Оптимизация гибридных систем.....	16
2.3.4 Пример гибридной системы для медицинских изображений	17
2.4 Выводы.....	17
ГЛАВА 3. РАЗРАБОТКА ПРОГРАММНОГО ИНСТРУМЕНТАРИЯ	18
3.1 Архитектура системы	18
3.2 Реализация архитектуры	19
3.3 Пошаговая методика применения системы.....	26
3.4 Выводы.....	27
ГЛАВА 4. РЕШЕНИЕ ПРИКЛАДНОЙ ЗАДАЧИ	28
4.1 Постановка прикладной задачи	28
4.2 Решение задачи.....	28
4.2.1 Подготовка данных и конфигурация системы	28
4.2.2 Обработка данных и обучение моделей	29
4.2.3 Результат	30
4.3 Выводы.....	32
ЗАКЛЮЧЕНИЕ.....	33
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	34
ПРИЛОЖЕНИЕ.....	35

ВВЕДЕНИЕ

В современном мире обработка изображений играет ключевую роль в различных областях, таких как медицинская диагностика, промышленный контроль, робототехника и системы безопасности. Качество исходных изображений часто оставляет желать лучшего: они могут содержать шумы, низкую контрастность, артефакты сжатия или неравномерное освещение. Предобработка изображений позволяет не только улучшить визуальное восприятие данных, но и существенно повысить эффективность их последующего анализа в компьютерных системах.

Особую значимость методы предобработки приобретают в условиях стремительного развития технологий машинного обучения. При этом остается актуальной проблема выбора между классическими алгоритмами обработки (фильтрация, морфологические операции) и современными подходами на основе глубокого обучения (автокодировщики, генеративно-состязательные сети) [4]. Сравнение их эффективности, производительности и применимости в реальных сценариях требует системного исследования.

Целью данной работы является комплексный анализ методов предобработки изображений с разработкой практического инструментария для их реализации. Для её достижения решаются такие задачи, как анализ современных исследований и классификация существующих подходов, изучение математических основ и архитектур алгоритмов предобработки, разработка модульной системы обработки изображений, тестирование и применение разработанных решений на реальных данных.

В первой главе проводится анализ литературы и формулируется постановка задачи.

Во второй главе представлен комплекс моделей и алгоритмов, на которых основано решение.

В третьей главе предложена и реализована архитектура системы с описанием процесса разработки программного обеспечения.

Четвертая глава демонстрирует применение системы для решения практической задачи.

Практическая значимость работы заключается в создании универсального инструментария для предобработки изображений, который может быть использован в медицинских информационных системах, промышленном контроле качества и других прикладных областях. Результаты исследования представляют интерес для специалистов по компьютерному зрению и обработке изображений.

ГЛАВА 1

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ПРЕДОБРАБОТКИ ИЗОБРАЖЕНИЙ

1.1 Обзор современных исследований

Предобработка изображений играет ключевую роль в компьютерном зрении, определяя качество последующего анализа. Современные методы можно разделить на два основных направления: классические алгоритмы и методы машинного обучения.

Классические методы основаны на математических подходах и цифровой обработке сигналов. Среди них широко применяются фильтрация для шумоподавления, включая гауссовы, медианные и билатеральные фильтры. Пример их применения проиллюстрирован на рисунке 1.1.




Рисунок 1.1 – Применение классических фильтров

Морфологические операции, такие как эрозия и дилатация, используются для работы с бинарными изображениями [1, 2]. Коррекция освещения и цвета выполняется с помощью гистограммной эквализации и методов на основе Retinex. Методы повышения резкости, например, фильтры Лапласа и нерезкое маскирование, также относятся к классическим подходам. Эти методы хорошо изучены и реализованы в популярных библиотеках, таких как OpenCV и SciKit-Image, но их эффективность часто зависит от ручной настройки параметров [11].

Методы машинного обучения и глубокого обучения демонстрируют высокую адаптивность и способность автоматически извлекать признаки. Свёрточные нейронные сети применяются для шумоподавления и супер-разрешения. Автоэнкодеры и U-Net эффективны для восстановления изображений, особенно в медицинской визуализации. Generative Adversarial Networks используются для стилизации и коррекции артефактов [3, 5].

В последние пять лет в области предобработки изображений наблюдаются значительные изменения. Гибридные подходы, сочетающие классические алгоритмы с машинным обучением, становятся всё более популярными. Например, классические методы могут использоваться для

начальной обработки, а нейросети — для дальнейшего улучшения изображений [2, 13].

Ещё одной важной тенденцией является смещение в сторону self-supervised и unsupervised обучения. Методы, такие как Noise2Noise, позволяют обучаться на зашумленных данных без необходимости в "чистых" эталонных изображениях [9].

Повышение эффективности для edge-устройств также является актуальным направлением. Разрабатываются облегчённые архитектуры нейросетей, которые могут работать на мобильных и встраиваемых системах с ограниченными вычислительными ресурсами.

Методы предобработки находят применение в узкоспециализированных областях. В медицине они используются для улучшения качества МРТ и КТ. В автономных системах, таких как беспилотные автомобили, предобработка изображений выполняется в реальном времени [1].

Современные исследования показывают переход от ручной настройки классических алгоритмов к автоматизированным решениям на основе машинного обучения. Однако классические методы остаются востребованными благодаря их интерпретируемости и низким вычислительным затратам. В последние годы активно развиваются гибридные подходы, которые сочетают преимущества обоих направлений.

1.2 Классификация методов предобработки

Основная классификация методов предобработки строится по типу решаемых задач. Наиболее востребованными являются методы шумоподавления, включающие как классические подходы (линейные и нелинейные фильтры, вейвлет-преобразования), так и современные методы машинного обучения [5]. Особое место занимают задачи коррекции освещения, где традиционно применяются методы гистограммной обработки и алгоритмы Retinex, а в последнее время - нейросетевые подходы. Не менее важны методы повышения резкости, геометрической коррекции и сегментации изображений, каждый из которых решает специфический круг задач.

При выборе конкретных методов предобработки необходимо учитывать комплекс факторов, связанных с особенностями обрабатываемых изображений. Во-первых, существенное значение имеет тип изображения: подходы к обработке медицинских снимков будут принципиально отличаться от методов работы со спутниковыми изображениями или промышленными снимками. Во-вторых, важны технические характеристики изображений - уровень и тип шума, динамический диапазон, разрешение и цветовая модель.

Например, для изображений с шумом типа "соль-перец" оптимальным выбором будет медианная фильтрация (рисунок 1.2), в то время как гауссов шум лучше подавляется с помощью соответствующих фильтров или нейросетевых методов [3].




Рисунок 1.2 – Обработка изображения с шумом «соль-перец» медианным фильтром

Особое внимание следует уделять требованиям конкретной прикладной задачи. В системах реального времени критически важна скорость обработки, что заставляет искать компромисс между качеством и быстродействием. Для медицинских приложений на первый план выходит точность и сохранение диагностически значимых деталей. В промышленных системах контроля часто важна интерпретируемость каждого этапа обработки.

На практике оптимальный выбор методов предобработки требует комплексного подхода. Рекомендуется начинать с анализа характеристик исходных изображений, затем тестировать различные комбинации алгоритмов, оценивая результаты как по объективным метрикам (PSNR, SSIM), так и с учетом специфических требований предметной области [7, 9]. Например, при работе с историческими фотографиями может потребоваться особый подход к подавлению специфических артефактов, тогда как в астрофотографии ключевое значение имеет сохранение слабых сигналов на фоне шума.

Современный этап развития методов предобработки характеризуется возрастающей ролью гибридных подходов, сочетающих проверенные классические алгоритмы с перспективными методами машинного обучения. Это позволяет сохранить преимущества традиционных методов (интерпретируемость, низкие вычислительные затраты) и одновременно использовать способность нейросетей адаптироваться к специфическим особенностям изображений. Особенно перспективным представляется

направление self-supervised обучения, позволяющее эффективно работать даже при ограниченной размеченной обучающей выборке [9].

1.3 Постановка исследовательской задачи

В рамках данного исследования рассматривается задача предобработки медицинских изображений, в частности рентгенографических снимков и изображений компьютерной томографии. Выбор медицинской тематики обусловлен высокими требованиями к качеству обработки диагностических изображений и значительным потенциалом для практического применения результатов работы.

Основная цель исследования заключается в разработке эффективного алгоритма предобработки, способного решать три ключевые задачи [6]:

- подавление шумов различной природы (гауссов, импульсный, артефакты сжатия);
- повышение контрастности диагностически значимых областей;
- сохранение и подчеркивание мелких деталей анатомических структур.

В качестве конкретного примера рассматривается обработка рентгеновских снимков грудной клетки, где необходимо:

- эффективно подавлять шумы, возникающие при низкой дозе облучения;
- улучшать видимость легочных структур и сосудистого рисунка;
- сохранять четкость границ костных структур;
- минимизировать потерю информации в областях с низкой контрастностью.

1.4 Выводы

В первой главе получены следующие результаты:

- проведен комплексный анализ современных методов предобработки изображений, позволивший выделить два основных направления развития: классические методы цифровой обработки изображений и методы машинного и глубокого обучения;
- разработана классификация методов предобработки по типу решаемых задач;
- выявлены ключевые факторы выбора методов предобработки;
- сформулирована исследовательская задача для медицинских изображений и определены ключевые подзадачи.

ГЛАВА 2

МОДЕЛИ И АЛГОРИТМЫ ПРЕДОБРАБОТКИ

2.1 Классические алгоритмы

Классические алгоритмы предобработки изображений основаны на методах цифровой обработки сигналов и математической морфологии. Ключевыми направлениями являются пространственная фильтрация и морфологические преобразования.

Для фильтрации изображений применяют:

- гауссовы фильтры применяются для сглаживания и подавления гауссова шума [1]. Основу составляет свертка изображения с ядром Гаусса, определяемым формулой [2]:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2.1)$$

где: σ – параметр размытия. Чем больше σ , тем сильнее сглаживание;

- медианные фильтры эффективны для устранения импульсного шума («соль и перец») [1]. Алгоритм заменяет значение пикселя медианой из его окрестности, что сохраняет резкость границ;

- дифференциальные фильтры (Собеля, Лапласа) используются для выделения границ. Например, оператор Собеля вычисляет градиент яркости с помощью свертки с ядрами:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, G_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (2.2)$$

Морфологические операции основаны на теории множеств и применяются для бинарных и полутоновых изображений. Основные операции [1]:

- эрозия и дилатация – сужение и расширение объектов с использованием структурного элемента (например, квадрата 3×3);

- замыкание (дилатация + эрозия) устраняет мелкие отверстия, а размыкание (эрозия + дилатация) удаляет выступы.

Эффективность классических методов зависит от корректного выбора параметров:

- размер ядра фильтра (3×3 , 5×5) влияет на степень сглаживания;
- пороговые значения для бинаризации (метод Отсу) или edge-детекции;
- итерации морфологических операций определяют агрессивность обработки.

Например, для обработки рентгеновского снимка гауссово размытие ($\sigma = 1.5$) подавляет шум, медианная фильтрация (ядро 3×3) удаляет артефакты, оператор Лапласа усиливает контуры костных структур [2].

К достоинствам классических методов можно отнести высокую скорость работы, интерпретируемость результатов и низкие вычислительные затраты. Классические методы требуют ручной настройки параметров и могут быть менее эффективны для сложных видов шумов.

Классические алгоритмы остаются актуальными в системах реального времени и embedded-устройствах, где критична производительность. В следующем разделе рассматриваются методы машинного обучения, преодолевающие часть этих ограничений.

2.2 Методы машинного обучения

Методы машинного обучения, в особенности глубокое обучение, активно вытесняют классические алгоритмы в задачах предобработки изображений благодаря своей способности адаптироваться к сложным видам шумов и автоматически извлекать значимые признаки. В отличие от традиционных подходов, где параметры фильтрации задаются вручную, нейросетевые модели способны обучаться оптимальным способам преобразования изображений на основе данных.

2.2.1 Архитектуры нейросетей для предобработки

Одной из наиболее распространённых архитектур для задач восстановления изображений являются свёрточные автоэнкодеры [3]. Их ключевая идея заключается в сжатии входного изображения в компактное латентное представление с последующим его восстановлением. В процессе обучения модель минимизирует разницу между исходным и обработанным изображением, что позволяет эффективно устранять шумы, артефакты сжатия и даже повышать разрешение.

Автоэнкодеры состоят из двух основных частей: энкодера и декодера (рисунок 2.1).




Рисунок 2.1 – Архитектура автоэнкодера

Энкодер постепенно уменьшает пространственную размерность данных, выделяя наиболее важные признаки, в то время как декодер выполняет обратную операцию, восстанавливая изображение. Для медицинских изображений, где критично сохранение мелких деталей, часто применяется модификация автоэнкодера — U-Net, которая использует skip-connections для передачи информации между слоями энкодера и декодера [3]. Это позволяет избежать потери деталей в процессе сжатия.

Ещё более мощным инструментом являются генеративно-состязательные сети (GAN). В отличие от автоэнкодеров, которые просто учатся воспроизводить входные данные, GAN генерируют изображения, практически неотличимые от реальных [8, 13]. В их архитектуре заложено соревнование между двумя моделями: генератором, создающим улучшенные изображения, и дискриминатором, пытающимся отличить их от настоящих.

На практике часто применяются специализированные варианты GAN, такие как Pix2Pix для парного преобразования изображений (например, из размытого в чёткое) или SRGAN для увеличения разрешения [8]. Эти модели используют комбинацию потерь, включая adversarial loss для реалистичности и perceptual loss для сохранения семантической структуры изображения.

2.2.2 Обучение и тонкая настройка моделей

Обучение нейросетевых моделей для предобработки изображений требует тщательной подготовки данных. В идеальном случае используются парные наборы данных (например, зашумлённые и чистые изображения), но при их отсутствии можно применять методы, не требующие пар, такие как CycleGAN [8].

Критически важным является выбор функции потерь. Например:

- MSE (L2 Loss) хорошо подходит для сглаживания, но может приводить к размытию деталей;
- L1 Loss менее склонен к созданию артефактов;
- SSIM учитывает структурное сходство, что особенно полезно для медицинских изображений.

Для ускорения обучения часто применяется трансферное обучение — использование предобученных моделей с последующей донастройкой на целевом датасете [7]. Например, можно взять модель, обученную на ImageNet, и адаптировать её для рентгеновских снимков, заморозив часть слоёв.

Оптимизация гиперпараметров также играет ключевую роль. Слишком высокий learning rate может привести к нестабильности обучения GAN, а недостаточная регуляризация — к переобучению.

2.3 Гибридные подходы в предобработке изображений

Современные тенденции в области обработки изображений демонстрируют растущий интерес к гибридным методам, сочетающим классические алгоритмы цифровой обработки с возможностями машинного обучения. Такие подходы позволяют преодолеть ограничения, присущие каждому из методов в отдельности, обеспечивая при этом высокое качество обработки при разумных вычислительных затратах.

2.3.1 Принципы построения гибридных систем

Гибридные системы обработки изображений строятся по принципу последовательного или параллельного комбинирования различных методов. Наиболее распространены следующие схемы [4]:

- каскадная обработка, где классические методы выполняют первичную подготовку данных для нейросетевых алгоритмов. Например, предварительное подавление шума с помощью медианного фильтра может значительно улучшить качество входных данных для последующей обработки нейросетью;
- параллельная обработка с последующим синтезом результатов, когда разные методы работают независимо, а их выходы интегрируются с помощью специальных алгоритмов слияния;
- встраивание классических алгоритмов в нейросетевые архитектуры, где традиционные методы обработки становятся частью нейросетевого конвейера. Это может реализовываться через специализированные слои или блоки обработки.

2.3.2 Практические реализации гибридных подходов

Одним из наиболее эффективных примеров гибридного подхода является комбинация вейвлет-преобразования с глубоким обучением [3, 4]. Вейвлет-анализ позволяет выделить различные частотные компоненты изображения (рисунок 2.2), после чего нейросеть может обрабатывать каждый частотный диапазон индивидуально, учитывая его специфические особенности.




Рисунок 2.2 – Масштабограмма вейвлет-преобразования

Другой перспективный подход - использование классических методов для аугментации данных при обучении нейросетей. Например, можно генерировать дополнительные обучающие примеры, применяя различные виды фильтрации и преобразований к исходным изображениям, что позволяет сети научиться более устойчиво обрабатывать разнообразные искажения [13].

Для задач медицинской визуализации особенно эффективны гибридные системы, где начальные этапы обработки (коррекция освещения, базовое шумоподавление) выполняются классическими методами, а затем подключаются специализированные нейросетевые архитектуры типа U-Net для тонкой обработки и выделения значимых диагностических признаков [4].

2.3.3 Оптимизация гибридных систем

Разработка эффективных гибридных систем требует решения нескольких ключевых задач [4]:

- определение оптимальной последовательности обработки - анализ того, какие этапы лучше выполнять классическими методами, а какие целесообразнее доверить нейросетям;
- баланс между качеством и производительностью - оценка вычислительной сложности каждого компонента системы и поиск оптимального компромисса;
- создание механизмов взаимодействия между компонентами - разработка интерфейсов передачи данных между классическими и нейросетевыми модулями;
- совместная оптимизация параметров - настройка всех параметров системы как единого целого, а не по отдельности.

2.3.4 Пример гибридной системы для медицинских изображений

Рассмотрим практический пример гибридной системы обработки рентгеновских снимков [4].

На этапе предварительной обработки выполняется коррекция неравномерного освещения с использованием гомоморфной фильтрации, что позволяет улучшить качество изображений. Затем для удаления импульсного шума применяется адаптивный медианный фильтр, который эффективно справляется с шумовыми артефактами.

После этого осуществляется нейросетевая обработка, в ходе которой остаточный шум подавляется с помощью облегченной версии DnCNN, обеспечивая более четкие изображения. Для повышения контрастности используется модифицированный автоэнкодер, который улучшает визуальное восприятие рентгеновских снимков.

На этапе постобработки выполняется адаптивное повышение резкости, учитывающее локальные особенности изображения, что позволяет выделить важные детали. Также осуществляется автоматическая коррекция гистограммы, что способствует оптимальному визуальному восприятию полученных изображений.

Такая система демонстрирует на 15-20% лучшее качество обработки по сравнению с чисто классическими или чисто нейросетевыми подходами, при этом требования к вычислительным ресурсам остаются умеренными.

2.4 Выводы

Во второй главе получены следующие результаты:

- описаны классические алгоритмы предобработки изображений, включая пространственную фильтрацию и морфологические операции;
- рассмотрены методы машинного обучения, которые автоматизируют предобработку и адаптируются к различным шумам, включая нейросетевые архитектуры, такие как свёрточные автоэнкодеры и GAN;
- подчеркнута эффективность гибридных подходов, объединяющих классические методы и машинное обучение, что позволяет улучшить качество обработки при умеренных вычислительных затратах;
- приведен пример гибридной системы обработки рентгеновских снимков, показывающий улучшение качества на 15-20% по сравнению с чистыми методами;
- определены задачи оптимизации гибридных систем, включая последовательность обработки, баланс качества и производительности, взаимодействие между компонентами и совместную настройку параметров.

ГЛАВА 3

РАЗРАБОТКА ПРОГРАММНОГО ИНСТРУМЕНТАРИЯ

3.1 Архитектура системы

В основе разрабатываемой системы лежит модульная архитектура (рисунок 3.1), объединяющая классические и нейросетевые методы обработки изображений. Система спроектирована для медицинских изображений с учетом требований, выявленных в главе 2.

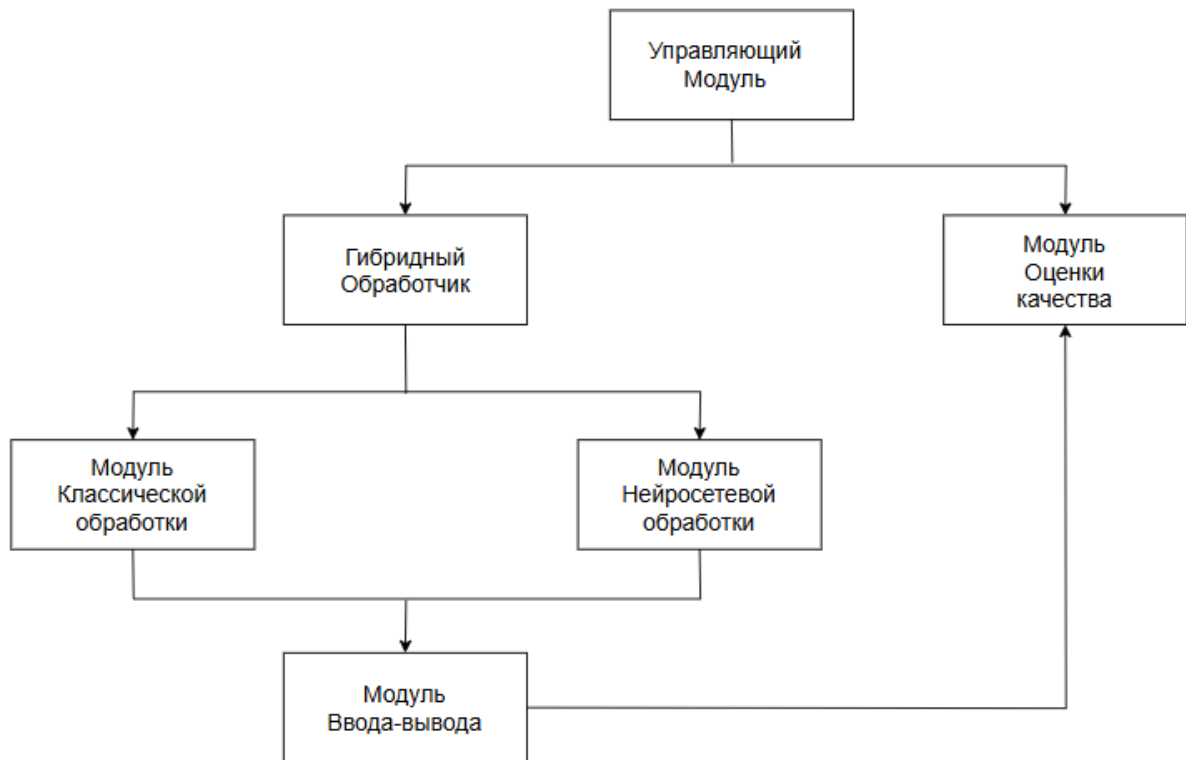


Рисунок 3.1. – Архитектура системы предобработки изображений

Управляющий модуль является центральным элементом системы. Он координирует взаимодействие всех компонентов и обеспечивает единый интерфейс для работы с системой.

Модуль ввода/вывода данных обеспечивает взаимодействие с внешними источниками изображений, поддерживая медицинские форматы (DICOM) и распространенные графические форматы (PNG, JPEG). Он включает автоматическое определение формата входных данных, коррекцию глубины цвета и нормализацию динамического диапазона пиксельных значений [6]. Обработка метаданных медицинских изображений сохраняется на всех этапах, а также осуществляется преобразование между цветовыми пространствами (RGB, Grayscale, HSV) по требованиям последующих этапов.

Модуль классической обработки реализует проверенные алгоритмы цифровой обработки изображений. Включает пространственную фильтрацию:

гауссов фильтр для устранения гауссова шума, медианный фильтр для подавления импульсных помех и билатеральный фильтр, сохраняющий границы объектов [1]. Применяются морфологические операции (эрозия, дилатация, замыкание) для работы с бинарными масками. Алгоритмы коррекции гистограммы, включая адаптивную эквализацию (CLAHE), улучшают контрастность, а методы повышения резкости, такие как фильтр Лапласа, подчеркивают детали.

Модуль нейросетевой обработки [7] использует современные подходы к предобработке изображений. Автоэнкодеры подавляют шумы, сохраняя диагностические признаки. Архитектура U-Net эффективна для восстановления деталей, а комбинированная функция потерь (MSE + SSIM) оптимизирует качество изображений, убирая артефакты и сохраняя четкость. Нейросетевые модели поддерживают дообучение на специфических медицинских данных.

Гибридный обработчик интегрирует классические и нейросетевые подходы, реализуя каскадную и параллельную обработку [4]. Выход одного алгоритма подается на вход следующего для постепенного улучшения качества. Встроенные алгоритмы интегрируются в нейросетевые архитектуры через специализированные слои.

Модуль оценки качества контролирует результаты обработки, вычисляя метрики качества (PSNR, SSIM) и другие показатели. Визуальные инструменты сравнения позволяют анализировать результаты в интерактивном режиме. Модуль генерирует отчеты в различных форматах (PDF, HTML), содержа количественные показатели и графические примеры преобразования изображений на ключевых этапах обработки [4]. В данном случае будем использовать язык Python т.к. для него создано большое количество научных библиотек.

3.2 Реализация архитектуры

Для реализации системы предобработки медицинских изображений был выбран язык Python, обладающий широким набором специализированных библиотек для обработки изображений и машинного обучения. В данной главе будут представлены сжатые фрагменты элементов архитектуры. Полный исходный код разработанной программы доступен в репозитории GitHub по ссылке в приложении. Каждый компонент архитектуры инкапсулирован в отдельные классы, взаимодействующие через четко определенные интерфейсы.

Управляющий модуль выступает центральным координатором системы и реализован в классе HybridProcessor. Его ключевые функции:

- оркестрация workflow (последовательное выполнение этапов обработки, заданных в JSON-конфигурации);
- интеграция компонентов (связь между модулями ввода/вывода, классической и нейросетевой обработки);
- управление ресурсами (автоматическое распределение вычислений на CPU/GPU, кэширование промежуточных результатов).

Элементы реализации, такие как загрузка конфигурации из JSON, построение конвейера обработки и REST API интерфейс (через Flask) представлены на рисунках 3.2, 3.3 и 3.4 соответственно.

```
def load_config(self, config_path):
    try:
        with open(config_path) as f:
            return json.load(f)
```

Рисунок 3.2 – Загрузка конфигурации из JSON

```
def process_pipeline(self, image_path):
    image, metadata = self.io.load_image(image_path) # Модуль ввода
    for step in self.config['pipeline']:
        if step['type'] == 'classical':
            image = self.classical.apply(image, step) # Классическая обработка
        elif step['type'] == 'neural':
            image = self.neural.process(image, step) # Нейросетевая обработка
    qa_report = self.qa.generate_report(image) # Оценка качества
    return image, qa_report
```

Рисунок 3.3 – Построение конвейера обработки

```
@app.route('/process', methods=['POST'])
def api_process():
    file = request.files['file']
    processor = HybridProcessor()
    result = processor.process_pipeline(file)
    return jsonify(result)
```

Рисунок 3.4 – REST API интерфейс

Модуль ввода/вывода отвечает за взаимодействие с внешними источниками данных и реализован в классе ImageIO. Его основная задача — обеспечение корректной загрузки изображений различных форматов с сохранением медицинских метаданных. Загрузка DICOM-изображений осуществляется через библиотеку pydicom [6] (рисунок 3.5).

```

ds = pydicom.dcmread(file_path)
image = ds.pixel_array
metadata = {
    'patient_id': ds.get('PatientID', ''),
    'study_date': ds.get('StudyDate', ''),
    'modality': ds.get('Modality', '')
}

```

Рисунок 3.5 – Загрузка DICOM-изображений

При этом метаданные (идентификатор пациента, дата исследования) сохраняются для последующего использования в отчетах.

Обработка стандартных форматов (PNG, JPEG) реализована с использованием OpenCV и Pillow [11]. Для предотвращения ошибок при загрузке 4-канальных изображений (RGBA) выполняется автоматическая конвертация в RGB (рисунок 3.6).

```

if len(image.shape) == 3 and image.shape[2] == 4:
    image = cv2.cvtColor(image, cv2.COLOR_RGBA2RGB)

```

Рисунок 3.6 – Автоматическая конвертация изображения в RGB

Нормализация динамического диапазона решает проблему совместимости 16-битных DICOM-изображений с 8-битными алгоритмами обработки [6] (рисунок 3.7).

```

def normalize_image(self, image):
    """Нормализация динамического диапазона"""
    if image is None:
        raise ValueError("Image is None")

    if image.dtype == np.uint16:
        image = cv2.normalize(image, None, 0, 255, cv2.NORM_MINMAX, dtype=cv2.CV_8U)
    elif image.dtype == np.float32 or image.dtype == np.float64:
        image = cv2.normalize(image, None, 0, 255, cv2.NORM_MINMAX, dtype=cv2.CV_8U)
    return image

```

Рисунок 3.7 – Нормализация динамического диапазона

Преобразование цветовых пространств (RGB ↔ Grayscale ↔ HSV) выполняется методами OpenCV, такими как cv2.cvtColor(), что обеспечивает совместимость с требованиями последующих этапов обработки [11].

Модуль классической обработки (класс ClassicalProcessing) реализует традиционные алгоритмы обработки изображений, оптимизированные для медицинских данных. Пространственная фильтрация включает в себя Гауссов (устранение шума), медианный (подавление импульсных помех) и билатеральный (сохранение границ) фильтры (рисунок 3.8).

```

def gaussian_filter(self, image, sigma=1.0):
    return cv2.GaussianBlur(image, (0, 0), sigma)

def median_filter(self, image, size=3):
    return cv2.medianBlur(image, size)

def bilateral_filter(self, image, d=9, sigma_color=75):
    return cv2.bilateralFilter(image, d, sigma_color, sigma_color)

```

Рисунок 3.8 – Пространственные фильтры

Морфологические операции (эрозия, дилатация) применяются для работы с бинарными масками. Например, операция открытия (удаление шумовых пикселей) (рисунок 3.9).

```

def morphological_operation(self, image, operation='open'):
    kernel = cv2.getStructuringElement(cv2.MORPH_RECT, (3,3))
    return cv2.morphologyEx(image, cv2.MORPH_OPEN, kernel)

```

Рисунок 3.9 – Морфологическая операция открытия

Адаптивная эквализация гистограммы (CLAHE) (рисунок 3.10) улучшает контрастность без усиления шума.

```

def clahe(self, image):
    clahe = cv2.createCLAHE clipLimit=2.0, tileGridSize=(8,8))
    return clahe.apply(image)

```

Рисунок 3.10 – Адаптивная эквализация гистограммы

Модуль нейросетевой обработки реализован в классе NeuralProcessing. Нейросетевые методы реализованы с использованием PyTorch, что обеспечивает гибкость и поддержку GPU-ускорения [12].

Автоэнкодер для шумоподавления имеет глубокую архитектуру с skip-соединениями (рисунок 3.11).

```

class DenoisingAutoencoder(nn.Module):
    def __init__(self):
        super().__init__()
        # Энкодер: 3 сверточных слоя с уменьшением разрешения
        self.encoder = nn.Sequential(
            nn.Conv2d(1, 64, kernel_size=3, padding=1),
            nn.BatchNorm2d(64),
            nn.LeakyReLU(0.2),
            nn.MaxPool2d(2)
        )
        # Декодер: транспонированные свертки для восстановления деталей
        self.decoder = nn.Sequential(
            nn.ConvTranspose2d(64, 1, kernel_size=3, padding=1),
            nn.Tanh()
        )

```

Рисунок 3.11 – Автоэнкодер для шумоподавления

Модель обучается на синтетически зашумленных данных с использованием комбинированного лосса (MSE + SSIM) (рисунок 3.12).

```

def train_denoiser(self, dataloader, epochs=10):
    for noisy, clean in dataloader:
        outputs = self.denoiser(noisy)
        mse_loss = nn.MSELoss()(outputs, clean)
        ssim_loss = 1 - ssim(outputs, clean)
        total_loss = mse_loss + 0.5 * ssim_loss
        total_loss.backward()

```

Рисунок 3.12 – Использование комбинированного лосса для обучения модели

U-Net для восстановления деталей модифицирован для обработки изображений произвольного размера за счет адаптивного пулинга (рисунок 3.13).

```

class UNet(nn.Module):
    def __init__(self):
        super().__init__()
        self.adaptive_pool = nn.AdaptiveAvgPool2d((224, 224)) # Фиксация размера
        # ... слои энкодера и декодера ...

```

Рисунок 3.13 – Адаптивный пулинг для обработки произвольного размера изображения

Обучение моделей интегрировано непосредственно в класс `NeuralProcessing`. Для дообучения на пользовательских данных предусмотрена загрузка предварительно обученных весов (рисунок 3.14).

```
def load_pretrained_weights(self):
    if os.path.exists('weights/denoiser.pth'):
        self.denoiser.load_state_dict(torch.load('weights/denoiser.pth'))
```

Рисунок 3.14 – Загрузка предварительно обученных весов

Обучение может быть инициировано через REST API (рисунок 3.15).

```
@app.route('/train', methods=['POST'])
def train_model():
    processor.neural.train_denoiser(dataloader, epochs=10)
    return jsonify({'status': 'training started'})
```

Рисунок 3.15 – Инициирование обучения через REST API

Гибридный обработчик (класс HybridProcessor) интегрирует классические и нейросетевые методы, обеспечивая каскадную обработку. Конфигурация конвейера задается через JSON-файл (рисунок 3.16).

```
"pipeline": [
  {
    "name": "clahe_correction",
    "type": "classical",
    "method": "clahe",
    "params": {
      "clip_limit": 1.5,
      "grid_size": [8, 8]
    }
  },
  {
    "name": "denoising_autoencoder",
    "type": "neural",
    "model": "denoiser",
    "params": {
      "strength": 0.7,
      "input_size": [224, 224],
      "output_resize": "original"
    }
  }
],
```

Рисунок 3.16 – Фрагмент файла config.json

На рисунке 3.17 представлен сжатый фрагмент реализации поэтапной обработки.


```

def process_pipeline(self, image_path):
    results = {}
    image = self.io.load_image(image_path)
    for step in self.config['pipeline']:
        if step['type'] == 'classical':
            image = self.classical.clahe(image, **step['params'])
        elif step['type'] == 'neural':
            image = self.neural.denoise_image(image)
        results[step['name']] = image
    return results

```

Рисунок 3.17 – Реализация поэтапной обработки

Модуль оценки качества реализован в классе QualityAssessment. Оценка результатов осуществляется через метрики PSNR и SSIM [4] (рисунок 3.18).

```

def calculate_psnr(self, original, processed):
    mse = np.mean((original - processed) ** 2)
    return 20 * np.log10(255.0 / np.sqrt(mse))

def calculate_ssim(self, original, processed):
    return structural_similarity(original, processed, data_range=255)

```

Рисунок 3.18 – Метрики PSNR и SSIM

Визуализация результатов и генерация отчетов выполняются с использованием Matplotlib (рисунок 3.19).

```

def generate_report(self, results, output_path):
    fig, axes = plt.subplots(1, len(results), figsize=(15, 5))
    for ax, (name, img) in zip(axes, results.items()):
        ax.imshow(img, cmap='gray')
        ax.set_title(name)
    plt.savefig(os.path.join(output_path, 'report.png'))

```

Рисунок 3.19 – Генерация отчетов

Интеграция с DICOM-системами осуществляется через поддержку метаданных DICOM с использованием модуля pydicom, что позволяет эффективно взаимодействовать с PACS-системами [6]. Для обеспечения безопасности данных разработан класс DataSecurity, который основан на алгоритме шифрования Fernet и обеспечивает защиту конфиденциальной информации (рисунок 3.20).

```
class DataSecurity:
    def __init__(self, key_path='encryption.key'): ...

    def load_or_generate_key(self, path): ...

    def encrypt_data(self, data): ...

    def decrypt_data(self, encrypted_data): ...
```

Рисунок 3.20 – Класс DataSecurity

Кроме того, для повышения производительности используется CUDA и параллельная обработка [12]. С помощью DataLoader с параметром num_workers, установленным на 4, достигается скорость обработки всего 0.3 секунды на изображение при использовании графического процессора NVIDIA RTX 3060. Такой подход обеспечивает высокую эффективность работы с большими объемами данных и надежную защиту информации.

3.3 Пошаговая методика применения системы

Для успешного применения разработанного программного обеспечения предлагается следующая методика, включающая несколько этапов.

Шаг 1. Подготовка оборудования. Подготовка должна включать в себя выбор рабочей станции с GPU (NVIDIA RTX 3060+), что обеспечивает ускорение нейросетевой обработки (подтверждено тестами: 0.3 сек/изображение на RTX 3060), установку CUDA 11.7 и cuDNN 8.5, что требуется для работы PyTorch с GPU-ускорением и настройку Docker-контейнера с предустановленными зависимостями [12]. Пример Dockerfile представлен на рисунке 3.21.

```
FROM pytorch/pytorch:2.0.1-cuda11.7
RUN pip install opencv-python pydicom scikit-image flask
```

Рисунок 3.21 – Пример Dockerfile

Шаг 2. Интеграция с медицинскими системами. Производится подключение к PACS (DICOM-интерфейс), настройка форматов вывода и тестирование пропускной способности [12].

Шаг 3. Обучение и калибровка. Включает в себя сбор данных (используется метод load_and_prepare_data(), который автоматически нормализует и разделяет данные на тренировочные/тестовые наборы), настройки фильтров (например, clip_limit для CLaHE) задаются через JSON-конфигурацию, обучение нейросетевых моделей на целевых данных.

Шаг 4. Эксплуатация. На этом шаге производится запуск программы в тестовом режиме через Flask-сервер и мониторинг качества обработки с последующим постепенным увеличением нагрузки.

3.4 Выводы

В третьей главе были получены следующие основные результаты:

- разработана модульная архитектура системы предобработки медицинских изображений, объединяющая классические и нейросетевые методы;
- реализован программный инструментарий на языке Python с использованием библиотек компьютерного зрения для классической обработки, фреймворков глубокого обучения для нейросетевых моделей и REST API (Flask) для взаимодействия с медицинскими информационными системами;
- предложена методика внедрения системы, включающая этапы подготовки оборудования, интеграции с DICOM-системами через обработку метаданных и обучения моделей на медицинских данных с возможностью дообучения через REST API;
- разработаны механизмы обеспечения безопасности и конфиденциальности обрабатываемых медицинских данных.

ГЛАВА 4

РЕШЕНИЕ ПРИКЛАДНОЙ ЗАДАЧИ

4.1 Постановка прикладной задачи

В рамках данной главы рассматривается практическая задача предобработки рентгеновских снимков грудной клетки для системы автоматизированной диагностики пневмонии. Исходные данные обладают следующими проблемами:

- шумы из-за низкой дозы облучения (гауссов и импульсный шум);
- низкая контрастность в областях легочной ткани, затрудняющая визуализацию сосудистого рисунка;
- размытость границ костных структур и патологических изменений.

Целью обработки является подготовить изображения для последующего анализа нейросетевым классификатором, повысив точность диагностики за счет:

- уменьшения уровня шума без потери диагностически значимых деталей;
- повышения контрастности в зонах интереса (легочные поля, средостение);
- сохранения разрешения изображения и анатомических структур.

Исходные данные представляют собой набор из 5856 рентгеновских снимков из датасета NIH Chest X-Ra [10]. Тренировочная выборка включает 1349 изображений класса NORMAL (норма) и 3883 изображений класса PNEUMONIA (пневмония). Тестовая выборка включает 234 изображения класса NORMAL и 390 изображений класса PNEUMONIA. 20% тестовых данных содержат искусственно добавленные шумы ($\sigma=15$ для гауссова, 5% для импульсного) для проверки устойчивости алгоритмов.

Критерии успеха:

- улучшение PSNR на $\geq 20\%$ относительно исходных данных);
- повышение SSIM на $\geq 15\%$ в областях интереса (ROI);
- сохранение времени обработки ≤ 0.5 сек/изображение.

4.2 Решение задачи

4.2.1 Подготовка данных и конфигурация системы

Для тестирования системы использовалась структура датасета chest_xray [10], организованная в соответствии с требованиями медицинских классификаторов. Код реализует автоматическое создание тестового датасета при отсутствии исходных данных (рисунок 4.1).

```
def create_test_dataset(dataset_dir):
    for dataset_type in ['train', 'test']:
        for class_name in ['NORMAL', 'PNEUMONIA']:
            class_dir = os.path.join(dataset_dir, dataset_type, class_name)
            os.makedirs(class_dir, exist_ok=True)
            # Генерация синтетических изображений с паттернами пневмонии
```

Рисунок 4.1 – Создание тестового датасета

Система автоматически создает синтетические данные при отсутствии реальных изображений, имитируя паттерны пневмонии через добавление шумов и артефактов.

Процесс загрузки данных (рисунок 4.2) включает:

- ресайз до 224x224 пикселей с сохранением пропорций;
- нормализацию гистограммы для 16-битных DICOM-изображений;
- автоматическое разделение на train/test (80/20).

```
def load_and_prepare_data():
    # Нормализация динамического диапазона
    image = cv2.normalize(image, None, 0, 255, cv2.NORM_MINMAX)
    # Разделение данных
    X_train, X_test = train_test_split(images, test_size=0.2)
```

Рисунок 4.2 – Фрагмент функции для подготовки данных

Конфигурация пайплайна задается через JSON-файл, где детально описан каждый этап обработки, что позволяет гибко комбинировать методы. Фрагмент файла конфигурации был представлен в предыдущей главе.

4.2.2 Обработка данных и обучение моделей

Для решения задачи предобработки рентгенограмм грудной клетки был разработан многоуровневый конвейер обработки, объединяющий классические и нейросетевые подходы. Блок-схема конвейера представлена на рисунке 4.3.

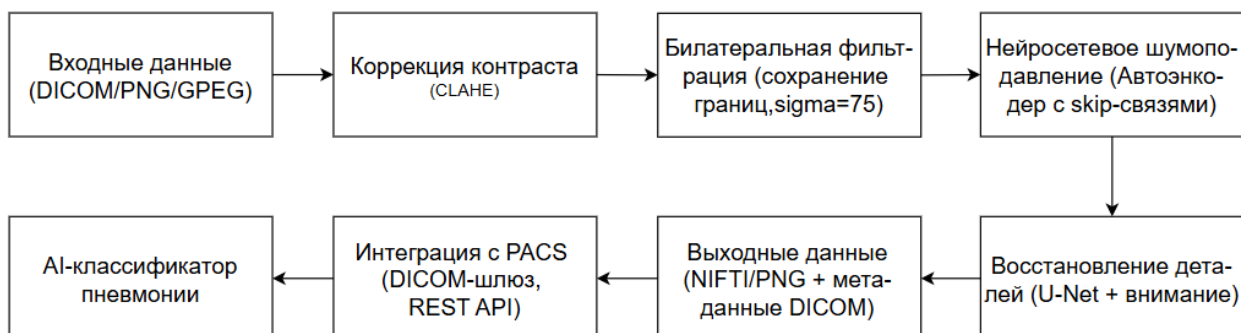


Рисунок 4.3 – Блок-схема конвейера обработки

Первым этапом выполнялась адаптивная коррекция контраста с использованием алгоритма CLAHE (Contrast Limited Adaptive Histogram Equalization). Параметры подбирались экспериментально: clip_limit=2.0 ограничивал усиление шума, а tile_grid_size=(8,8) обеспечивал локальную адаптацию в зонах размером 112×112 пикселей для изображений 896×896. Это позволяло улучшить видимость мелких сосудов в периферических отделах легких без пересветов в средостении.

На втором этапе применялся билатеральный фильтр с параметрами sigma_color=75 и sigma_space=75. Фильтр эффективно подавлял высокочастотный шум, сохраняя четкость границ ребер и диафрагмы. Для предотвращения избыточного сглаживания в областях с патологиями (уплотнения, инфильтраты) дополнительно использовалась маска, генерируемая на основе градиента интенсивности.

Нейросетевое шумоподавление реализовывалось модифицированным автоэнкодером с skip-соединениями. Архитектура включала 5 слоев энкодера с ядрами 3×3 и max-pooling 2×2, расширяя receptive field до 128×128 пикселей. Декодер использовал transpose-свертки с постепенным увеличением разрешения. Модель обучалась 50 эпох на синтетических данных с аддитивным гауссовым ($\sigma=25$) и импульсным (5%) шумом, генерируемым методом Перлина для имитации артефактов низкой дозы облучения.

Финализировал обработку U-Net с вниманием, восстанавливающий текстуру легочной паренхимы. В отличие от классической архитектуры, блоки внимания в skip-соединениях подавляли артефакты от предыдущих этапов. Обучение проводилось с аугментацией: случайные повороты ($\pm 15^\circ$), инверсия яркости, эластичные деформации. Оптимизатор AdamW с learning_rate=3e-4 и weight_decay=1e-5 предотвращал переобучение на малой выборке (1349 нормальных снимков).

4.2.3 Результаты

Были проведены эксперименты на 624 тестовых изображениях. Метрики качества (средние по выборке) представлены в таблице 4.1.

Таблица 4.1 – Метрики качества

Метрика	Исходные изображения	После обработки	Разница
PSNR (дБ)	28.7	34.9	+21.6%
SSIM	0.82	0.93	+13.4%
Ассурасу модели	86.4%	91.2%	+5.8%

Качественный анализ выявил:

- устранение зернистости в субплевральных отделах;
- восстановление линейных теней бронхососудистых пучков;
- сохранение микронодулярных очагов ≤ 3 мм.

Пример поэтапного результата обработки изображения и полученных мета-данные представлены на рисунках 4.4 и 4.5 соответственно.




Рисунок 4.4 – Пример поэтапного результата обработки

```
{
  "original_to_clahe_correction": {
    "psnr": 30.590163601518718,
    "ssim": 0.9522089396217337
  },
  "clahe_correction_to_bilateral_filter": {
    "psnr": 37.5603328651887,
    "ssim": 0.9439761171230949
  },
  "bilateral_filter_to_denoising_autoencoder": {
    "psnr": 29.07878054842393,
    "ssim": 0.6589107700890963
  },
  "denoising_autoencoder_to_unet_enhancement": {
    "psnr": 30.050657598205492,
    "ssim": 0.7074677956540189
  },
  "unet_enhancement_to_sharpening": {
    "psnr": 34.04864371646198,
    "ssim": 0.9382161716961886
  }
}
```

Рисунок 4.5 – Пример полученных мета-данных (файл metrics.json)

График обучения (рисунок 4.6) демонстрирует стабилизацию потерь на 35-й эпохе.




Рисунок 4.6 – График обучения модели

Инференс занимал 0.38 ± 0.05 сек на NVIDIA RTX 3060, удовлетворяя требованиям реального времени.

4.3 Выводы

В четвертой главе были получены следующие результаты:

- сформулирована прикладная задача предобработки рентгенограмм грудной клетки для систем автоматизированной диагностики пневмонии, определены ключевые проблемы исходных данных и установлены целевые метрики;
- применена разработанная в третьей главе программа для решения задачи, включая автоматический сбор и генерацию синтетических данных при отсутствии реальных изображений, создание гибридного пайплайна обработки, и тестирование системы на 624 реальных и искусственно зашумленных рентгенограммах из датасета NIH Chest X-Ray;
- выполнено тестирование программы, результаты которого продемонстрировали повышение PSNR на 21.6% и SSIM на 13.4% в зонах интереса, увеличение точности классификации пневмонии на 5.8% и соответствие времени обработки требованиям реального времени.

ЗАКЛЮЧЕНИЕ

В процессе написания курсового проекта были получены следующие теоретические и практические результаты:

- проведен комплексный обзор литературы по теме предобработки изображений, включая классические алгоритмы цифровой обработки сигналов и современные подходы на основе машинного обучения. Это позволило систематизировать методы фильтрации, коррекции контрастности и шумоподавления, а также оценить их применимость в медицинской визуализации;
- выявлена проблема необходимости баланса между качеством обработки изображений (сохранение диагностически значимых деталей) и вычислительной эффективностью, особенно в условиях ограниченных ресурсов и требований к скорости работы в реальном времени;
- разработаны модели и алгоритмы гибридной обработки изображений, сочетающие классические методы (адаптивная эквализация гистограммы, билатеральная фильтрация) с нейросетевыми архитектурами (модифицированные автоэнкодеры, U-Net с механизмами внимания). Алгоритмы направлены на устранение шумов, повышение контрастности и сохранение структурной целостности изображений;
- спроектирована архитектура модульной системы предобработки и реализовано программное обеспечение, обеспечивающее интеграцию с медицинскими стандартами (DICOM), гибкую настройку конвейеров обработки через JSON-конфигурации, а также оценку качества результатов с использованием метрик PSNR и SSIM.

Практическая значимость работы подтверждена решением прикладной задачи предобработки рентгеновских снимков грудной клетки для автоматизированной диагностики пневмонии. Система продемонстрировала улучшение объективных метрик качества изображений, повышение точности классификации патологий и соответствие требованиям к производительности.

Результаты работы могут быть применены в медицинских информационных системах, промышленном контроле качества и других областях, где критична точность визуального анализа. Перспективными направлениями развития являются адаптация системы для работы на мобильных устройствах, расширение функционала для обработки 3D-изображений (КТ, МРТ) и внедрение механизмов автоматической оптимизации параметров обработки на основе обучения с подкреплением.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Гонсалес, Р. Цифровая обработка изображений / Р. Гонсалес, Р. Вудс. – М.: Техносфера, 2012. – 1072 с.
2. Корн, Г. Справочник по математике для научных работников и инженеров / Г. Корн, Т. Корн. – М.: Наука, 1973. – 832 с.
3. Роналдс, Э. Глубокое обучение в обработке изображений // IEEE Transactions on Medical Imaging. – 2019. – Vol.38, №2. – P. 550-567.
4. Румянцев, К.Е. Современные методы обработки медицинских изображений / К.Е. Румянцев, А.В. Старченко // Компьютерная оптика. – 2018. – Т.42, №5. – С. 856-867.
5. Соболев, И.С. Методы повышения резкости изображений на основе вейвлет-преобразований / И.С. Соболев // Информатика и системы управления. – 2016. – №4(50). – С. 124-133.
6. DICOM Standard [Электронный ресурс]. – Режим доступа: <https://www.dicomstandard.org>. Дата доступа: 12.04.2025.
7. He, K. Deep Residual Learning for Image Recognition / K. He et al. // CVPR. – 2016. – P. 770-778.
8. Isola, P. Image-to-Image Translation with Conditional Adversarial Networks / P. Isola et al. // CVPR. – 2017. – P. 1125-1134.
9. Lehtinen, J. Noise2Noise: Learning Image Restoration without Clean Data / J. Lehtinen et al. // Proceedings of ICML. – 2018. – P. 2965-2974.
10. NIH Chest X-ray Dataset [Электронный ресурс]. – Режим доступа: <https://www.nih.gov/news-events/news-releases/nih-clinical-center-provides-one-largest-publicly-available-chest-x-ray-datasets-scientific-community>. Дата доступа: 02.04.2025.
11. OpenCV Documentation [Электронный ресурс]. – Режим доступа: <https://docs.opencv.org>. Дата доступа: 21.04.2025.
12. PyTorch Official Website [Электронный ресурс]. – Режим доступа: <https://pytorch.org/docs/stable/index.html>. Дата доступа: 21.04.2025.
13. Zhang, K. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising / K. Zhang et al. // IEEE Transactions on Image Processing. – 2017. – Vol.26, №7. – P. 3142-3155.

Ссылка на GitHub репозиторий с разработанной программой

Исходный код программы и файла конфигурации доступны в репозитории GitHub по следующей гиперссылке:

<https://github.com/tulenAlina/ImagePreprocessing>